

고차원 데이터  $\rightarrow$  시각화, 분석 어려움.

$\hookrightarrow$  ~~최~~ 일부 차원에만 대부분의 정보가 포함되는 경우가 많다.

$\hookrightarrow$  ~~다른 많은 것~~ 다른 차원은 데이터의 주요 속성을 설명하는데 반드시 필요한 건 아님.

차원을 축소하여  
데이터를 설명.

차원 축소  $\Rightarrow$  정보 손실 불가피.


but, 가장 많은 정보를 제공하는 차원을 찾아

데이터에 대해 이 차원만 남기고  
~~나~~ ~~차원~~ ~~은~~ 데이터를 내지는 ~~것~~ 제거.

\* 차원 축소의 중심적인 역할: 직교투영법. (orthogonal projection)

⑨ 1차원 하위공간에 투영.

$\pi_u(x)$  :  $x$ 를  $u$ 에 직교투영하는 방법.



- 두 평면의 2가지 중요속성  $\hookrightarrow$
1.  $\pi_u(x) \in u. \Rightarrow \exists \lambda \in \mathbb{R} : \pi_u(x) = \lambda b$  (as  $\pi_u(x) \in u$ )
  2.  $\langle b, \pi_u(x) - x \rangle = 0$  (orthogonality)

$\hookrightarrow$  이 두 가지 속성을 이용하여  $\pi_u(x)$ 을 구해보자.

- 2가지 경우
1.  $\exists \lambda \in \mathbb{K} : \pi_U(x) = \lambda b$  (as  $\pi_U(x) \in U$ )
  2.  $\langle b, \pi_U(x) - x \rangle = 0$  (orthogonality)

$$\langle b, \pi_U(x) - x \rangle = 0$$

$$\Leftrightarrow \langle b, \pi_U(x) \rangle - \langle b, x \rangle = 0$$


$$\dots (\because w(u+v) = (w \cdot u) + (w \cdot v))$$

~~scribble~~

$$\Leftrightarrow \langle b, \lambda b \rangle - \langle b, x \rangle = 0 \quad (\because \pi_U(x) = \lambda b)$$

$$\Leftrightarrow \lambda \cdot \|b\|^2 - \langle b, x \rangle = 0 \quad (\because b \cdot b = \|b\|^2)$$

$$\Leftrightarrow \lambda = \frac{\langle b, x \rangle}{\|b\|^2}$$



$\lambda$ :  $\lambda$ 가  $b$ 에 대한  $x$ 의 투영 계수. (투영 계수 크기)

$$\Rightarrow \pi_U(x) = \lambda b$$

$$= \frac{\langle b, x \rangle}{\|b\|^2} \times b$$

$$\stackrel{\text{scalar}}{=} \frac{(b^T \cdot x)b}{\|b\|^2}$$

(스칼라 값을 뒤로 빼면,

$b^T \cdot x$  는 스칼라 값이다. 즉  $\frac{\text{스칼라} \times b}{\|b\|^2}$  이다.

$$\Downarrow$$

$$b(\text{스칼라}) = (\text{스칼라})b$$

$$\frac{b(b^T \cdot x)}{\|b\|^2}$$

$$= \frac{b(b^T \cdot x)}{\|b\|^2}$$

인디,  $b(b^T \cdot x) = (b \cdot b^T)x$  가 되므로 (정확하게 증명 가능)

$$= \frac{(b \cdot b^T)x}{\|b\|^2}$$

한편  $b \cdot b^T$  는  $(n \times 1) \cdot (1 \times n)$  으로  $(n \times n)$  과 대칭행렬이 되므로. 이는 행렬과 벡터의 곱으로 표현된다.

$$= \frac{b \cdot b^T}{\|b\|^2} \times$$

이다. 이때  $\frac{b \cdot b^T}{\|b\|^2}$  을 투영행렬 (Projection Matrix)

이라고 한다. 그리고 이 투영행렬은 2차원의 ~~공간~~  $\mathbb{R}^2$  에서 1차원의 부분공간으로 투영하는 역할을 한다. (변환)

$$\pi_u(x) = \frac{b \cdot b^T}{\|b\|^2} x$$

$$* \begin{cases} b^T b \Rightarrow (1 \times 1) \\ b \cdot b^T \Rightarrow (n \times n) \end{cases}$$

만약  $\|b\|=1$  이라면,  $\lambda = \frac{b^T x}{\|b\|^2} = b^T x$


~~$$\pi_u(x) = \frac{(b b^T) x}{\|b\|^2} = b (b^T x) = b \lambda = \lambda b$$~~

$$\pi_u(x) = \lambda b = b \lambda = \boxed{(b b^T) x}$$

즉,  $\|b\|=1$  일때  $\lambda = b^T x$ ,  $\pi_u(x) = (b b^T) x$  로 간단히 표현할 수 있다.

① 고차원 (부분공간) 하위공간을 두어.

- 1차원 부분공간으로의 투영과 동일한 계법을 사용한다.



$$\begin{cases} b_1 \cdot (x - \pi_U(x)) = 0 \\ b_2 \cdot (x - \pi_U(x)) = 0 \end{cases}$$

$$\pi_U(x) = \lambda_1 b_1 + \lambda_2 b_2$$

x가 M차원 벡터이고

부분공간 U가 M차원 공간이라는 것으로 확장하여 생각

$$\hookrightarrow (i) \pi_U(x) = \sum_{i=1}^M \lambda_i b_i \quad (\because \pi_U(x) \in U, U \in \mathbb{R}^M)$$

$$(ii) \langle \pi_U(x) - x, b_i \rangle = 0 \quad (i=1, 2, \dots, M)$$

$$\hookrightarrow \text{두 성질을 이용해 } \lambda = \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \vdots \\ \lambda_M \end{bmatrix} \text{ (Mx1), } B = \begin{bmatrix} b_1 & b_2 & \dots & b_M \end{bmatrix} \text{ (PxM) 을 정의.}$$

$\lambda$ :  $\lambda_i$ 들로 구성된 열벡터,  $B$ : 기저 U를 구성하는 모든 기저벡터를 결합한 행렬

벡터공간: 기저벡터들의 선형결합으로만 이루어지는 모든 벡터들의 집합  
\* 기저 = 기저벡터들의 집합  
기저벡터: 벡터공간을 구성하는 기본 단위 역할을 수행하는 벡터.

$U = [b_1, b_2] \dots U$ 는  $b_1, b_2$ 의 선형결합으로 구성된 벡터공간.

$\pi_U(x) \in U \rightarrow \pi_U(x)$ 는 기저벡터  $b_1$ 과  $b_2$ 의 선형결합으로 표현될 수 있다.

\* 벡터 x를 기저 U에 포함 벡터 b가 없을 때, 이는, 벡터 x를 기저 U가 표현하는 벡터공간으로 선형변환 했다는걸 의미한다.

$\hookrightarrow$  벡터 x의 좌표를 기저 U의 좌표계로 변환하는 것을 의미함.

$\hookrightarrow$  변환된 벡터 b는 원래의 벡터 x가 기저 U의 좌표계에서 어떻게 표현되었는지를 의미한다.

(Mx1)

(DxM)

 $\lambda = \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \vdots \\ \lambda_M \end{bmatrix}, \quad B = [b_1, b_2, \dots, b_M]$  을 이용해 다음과 같이 표현 가능.

$$\cdot \quad \underline{\Pi_u(x)} = \underline{\sum_{i=1}^M \lambda_i b_i} = \underline{B\lambda} \quad (1 \times 1)$$

$$\cdot \quad \langle \Pi_u(x) = X, b_i \rangle = \langle B\lambda - X, b_i \rangle = 0 \quad (\text{직교하되.})$$

이는 선형성 조건을 이용하면

$$\langle B\lambda, b_i \rangle - \langle X, b_i \rangle = 0 \quad \text{각각, } (i=1, 2, \dots, M)$$

$$\Leftrightarrow (B \cdot \lambda)^T b_i - (X)^T b_i = 0 \quad (\because \langle a, b \rangle = a^T \cdot b \quad \dots \text{내적의 정의})$$

$$\Leftrightarrow \lambda^T B^T \cdot b_i - X^T \cdot b_i = 0 \quad (\because (AB)^T = B^T A^T, (a b)^T = b^T a^T, \neq (A b)^T = b^T A^T)$$

$i=1, 2, \dots, M$

위의 식을  $b_1, b_2, \dots, b_M$  모든 경우에 대해 표현하면, 행렬로 표현하면,

$$\lambda^T B^T B - X^T B = 0 \quad (0 = \text{영행렬})$$

이 식을 통해 벡터  $\lambda$ 를 식별하자 함.

$$\Leftrightarrow \lambda^T (B^T B) = X^T B$$

$$\Leftrightarrow \lambda^T = (X^T B) (B^T B)^{-1}$$

$$\begin{aligned} \Leftrightarrow \lambda &= ((X^T B) (B^T B)^{-1})^T \\ &= ((B^T B)^{-1})^T (X^T B)^T \\ &= ((B^T B)^T)^{-1} (X^T B)^T \end{aligned}$$

$$\lambda = (B^T B)^{-1} B^T X$$

한편  $\Pi_u(X) = B\lambda$  이므로,

$$= \underline{B(B^T B)^{-1} B^T X} \quad \text{이다.} \quad \text{이때,}$$

$B(B^T B)^{-1} B^T$  는 투영행렬이다  $\Rightarrow$  D차원 벡터  $X$  을

M차원 공간(부분공간)으로 투영하는

투영행렬이다.

한편  $B$ 가 직교행렬(행벡터들이 서로 수직)이라면

$$B^T B = I \quad \text{이므로}$$

$$\Pi_u(X) = B B^T X \quad \text{이다.}$$



또한 투영행렬  $P = B(B^T B)^{-1} B^T$  는 대칭행렬이다.

$$\therefore P^T = [B(B^T B)^{-1} B^T]^T$$

$$= B [(B^T B)^{-1}]^T B^T$$

$$= B ((B^T B)^T)^{-1} B^T$$

$$P^T = B (B^T B)^{-1} B^T = P$$

즉  $P^T = P$  이므로

투영행렬  $P$  는 대칭행렬이다.

★ 한편, 벡터  $x$  를 부분공간  $U$  에 투영해 나온 벡터  $\Pi_U(x)$  를 ~~다시~~ 부분공간  $U$  에 다시 투영하면, 자기 자신인  $\Pi_U(x)$  가 나온다

↳ 왜냐하면  $\Pi_U(x)$  는 이미  $U$  공간에 있으므로, 투영을 해도 그 값은 자기 자신이 나오지 않게 됨.

↳ 같은 부분공간에 여러번 투영해도 그 결과는 <sup>해당 부분공간에</sup> 첫 번째로 (한 번) 투영한 결과와 같다.

$$\text{즉, } \Pi_U(\Pi_U(x)) = \Pi_U(x) \text{ 이다.}$$